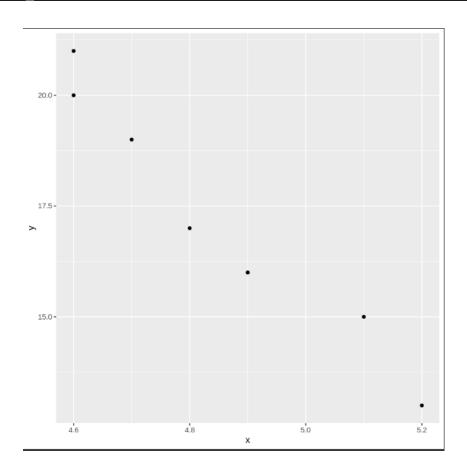
CURSO: CIÊNCIA DE DADOS (Big Data Processing and Analytics)
POLO DE APOIO PRESENCIAL: HIGIENÓPOLIS
SEMESTRE: 1°
COMPONENTE CURRICULAR / TEMA: BIG DATA ANALYTICS
NOME COMPLETO DO ALUNO: GIULIANO GIGLIO DE BRITO
TIA: 92277276
NOME DO PROFESSOR: VICENTE CALVO

1

```
dados = data.frame (

x = c(5.2, 5.1, 4.9, 4.6, 4.7, 4.8, 4.6, 4.9),
y = c(13, 15, 16, 20, 19, 17, 21, 16)
)
dados
```

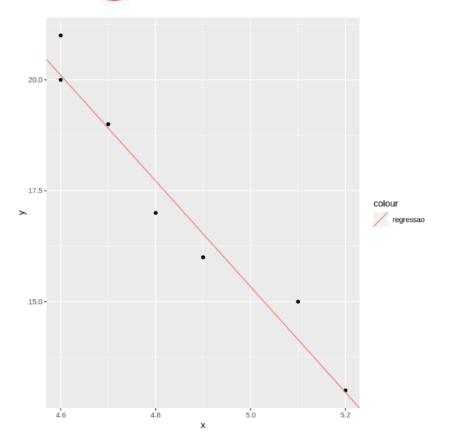
```
ggplot(dados, aes(y = y, x = x)) + geom point()
```



```
reg = lm(formula = y \sim x, data = dados)
   summary(reg)
₽
   lm(formula = y \sim x, data = dados)
   Residuals:
       Min
                1Q Median
                                 3Q
   -0.72059 -0.52941 -0.02941 0.27941 0.89706
   Coefficients:
              Estimate Std. Error t value Pr(>|t|)
   (Intercept) 74.897 5.514 13.58 9.88e-06 ***
                          1.136 -10.49 4.42e-05 ***
               -11.912
   Signif. codes: 0 (***, 0.001 (**, 0.05 (., 0.1 (, ) 1
   Residual standard error: 0.6624 on 6 degrees of freedom
   Multiple R-squared: 0.9483, Adjusted R-squared: 0.9396
   F-statistic: 110 on 1 and 6 DF, p-value: 4.416e-05
```

Os resíduos máximos e mínimos não estão 100% simétricos, entretanto, não estão longe de estarem simétricos. Os coeficientes são relevantes pois estão com o código ***, o que é ótimo. O R quadrado está bom por estar próximo a 1.

```
cofs = coefficients(reg)
p = ggplot(dados, aes(y = y, x = x)) +
  geom_point() +
  geom_abline(aes(intercept = cofs[1], slope = cofs[2], color = 'regressao'))
p
```



2

```
dt = read.csv('gapminder_tull.csv')
> head(df)
      country year population continent life_exp
1 Afghanistan 1952
                       8425333
                                     Asia
                                            28.801
2 Afghanistan 1957
                       9240934
                                     Asia
                                            30.332
                      10267083
                                            31.997
3 Afghanistan 1962
                                     Asia
4 Afghanistan 1967
                      11537966
                                            34.020
                                     Asia
                      13079460
                                            36.088
5 Afghanistan 1972
                                     Asia
                      14880372
6 Afghanistan 1977
                                            38.438
                                     Asia
gdp_cap
1 779.4453
2 820.8530
3 853.1007
4 836.1971
5 739.9811
6 786.1134
```



```
> summary(df)
                                     population
   country
                         year
 Length: 1704
                                   Min. :6.001e+04
                    Min.
                          :1952
 Class :character
                    1st Qu.:1966
                                   1st Qu.:2.794e+06
                                   Median: 7.024e+06
 Mode :character
                    Median :1980
                                   Mean :2.960e+07
                          :1980
                    Mean
                    3rd Qu.:1993
                                   3rd Qu.:1.959e+07
                          :2007
                                   Max. :1.319e+09
                    Max.
  continent
                      life_exp
                                       gdp_cap
 Length: 1704
                    Min. :23.60
                                    Min. :
                                               241.2
 Class :character
                    1st Qu.:48.20
                                    1st Qu.:
                                             1202.1
 Mode :character
                    Median :60.71
                                    Median : 3531.8
                          :59.47
                                              7215.3
                    Mean
                                    Mean
                    3rd Qu.:70.85
                                    3rd Qu.: 9325.5
                    Max. :82.60
                                    Max. :113523.1
、 |
> str(df)
'data.frame': 1704 obs. of 6 variables:
$ country : chr "Afghanistan" "Afghanistan" "Afghanistan" "Afghanis
tan" ...
            : int 1952 1957 1962 1967 1972 1977 1982 1987 1992 1997
 $ year
 $ population: int 8425333 9240934 10267083 11537966 13079460 14880372
 12881816 13867957 16317921 22227415 ...
 $ continent : chr "Asia" "Asia" "Asia" "Asia" ...
 $ life_exp : num 28.8 30.3 32 34 36.1 ...
```

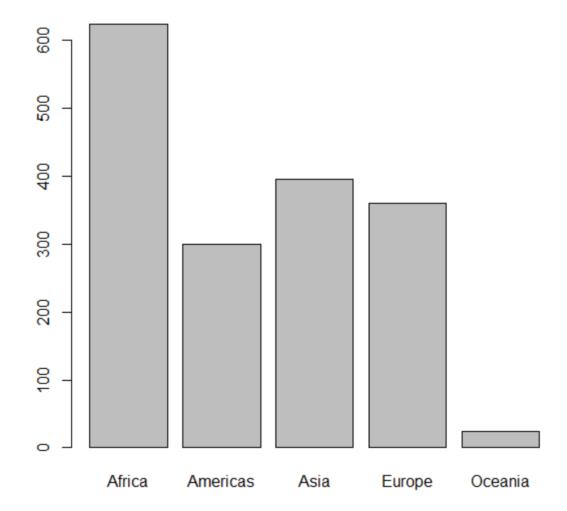
```
print('country : chr : Qualitativa Nominal
    year : int : Quantitativa discreta
    population : num : Quantitativa discreta
    continent: chr : Qualitativa Nominal
    life_exp : num : Quantitativa Ordinal
    gdp_cap : num : Qualitativa Ordinal')
```

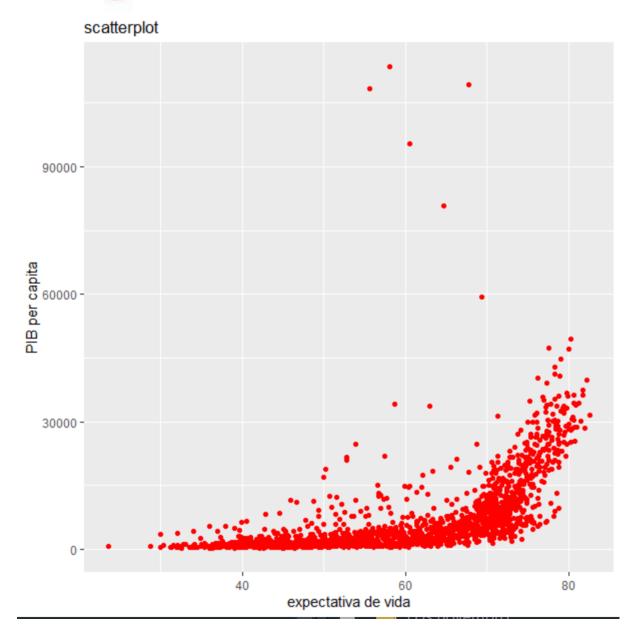
: num 779 821 853 836 740 ...

\$ gdp_cap

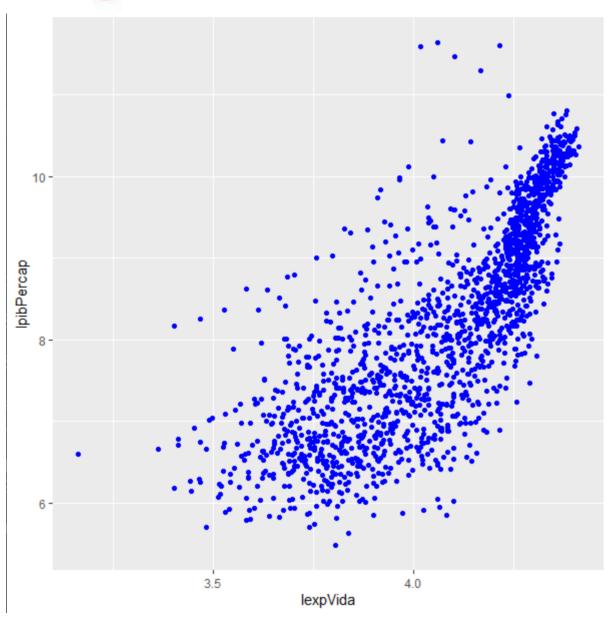
```
> prop.table(table_continent) * 100
```

Africa Americas Asia Europe Oceania 36.619718 17.605634 23.239437 21.126761 1.408451





```
> df2 = df
> df2["lpibPercap"] <- lpibPercap</pre>
> df2["lexpVida"] <- lexpVida</pre>
> str(df2)
'data.frame': 1704 obs. of 8 variables:
 $ country : chr "Afghanistan" "Afghanistan" "Afghanistan" "Afghan
istan" ...
             : int 1952 1957 1962 1967 1972 1977 1982 1987 1992 1997
 $ year
 $ population: int 8425333 9240934 10267083 11537966 13079460 148803
72 12881816 13867957 16317921 22227415
 $ continent : chr "Asia" "Asia" "Asia" "Asia" ...
 $ life_exp : num 28.8 30.3 32 34 36.1 ...
 $ gdp_cap : num 779 821 853 836 740 ...
 $ lpibPercap: num 6.66 6.71 6.75 6.73 6.61 ...
                    3.36 3.41 3.47 3.53 3.59 ...
 $ lexp∨ida : num
```



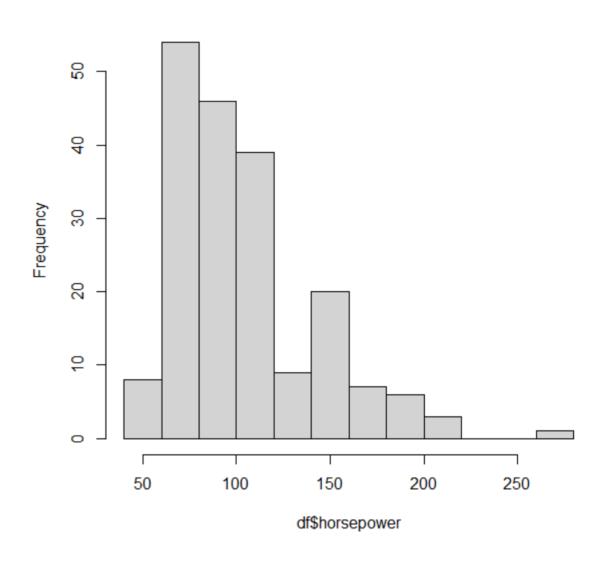
```
> reg = lm(formula = lpibPercap~lexpVida, data = df2)
> summary(reg)
Call:
lm(formula = lpibPercap ~ lexpVida, data = df2)
Residuals:
   Min
             1Q Median
                                    Max
-2.4062 -0.5298 -0.0099 0.5051
                                 3.6116
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -8.82872
                       0.32757
                                 -26.95
                                          <2e-16 ***
lexpVida
           4.18428
                        0.08055
                                  51.95
                                          <2e-16 ***
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 0.7721 on 1702 degrees of freedom
Multiple R-squared: 0.6132, Adjusted R-squared: 0.613
F-statistic: 2698 on 1 and 1702 DF, p-value: < 2.2e-16
```

Talvez ao aplicar log apenas em uma das variáveis, poderíamos reduzir o R quadrado e melhorar a simetria dos resíduos.

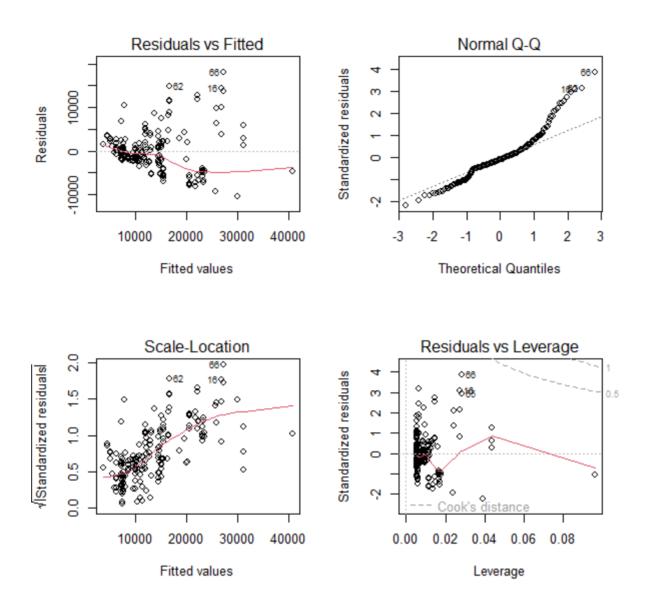
3

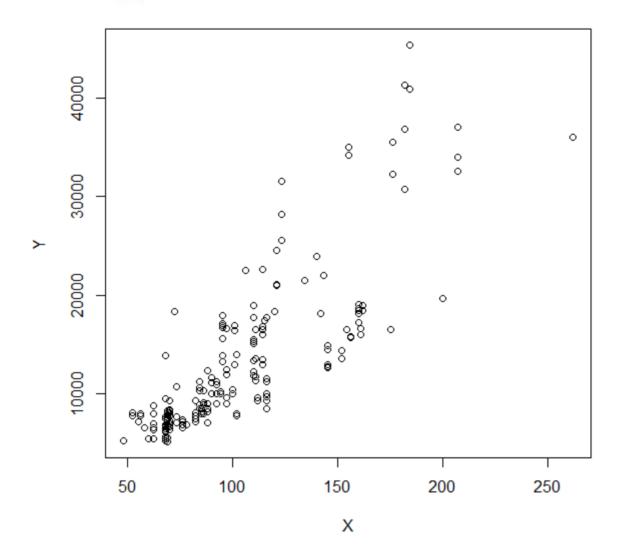
> summary(df) make Length:193 Class :character Mode :character	fuel.type Length:193 Class :character Mode :character	aspiration Length:193 Class :character Mode :character		body.style Length:193 Class :chara Mode :chara	
drive.wheels Length:193 Class :character Mode :character	engine.location Length:193 Class :character Mode :character	wheel.base Length:193 Class :character Mode :character			
height Length:193 Class :character Mode :character	Min. :1488 Lei 1st Qu.:2145 Cla	ngth:193 M ass :character 1 de :character M M 3	lin. : 3.00 Mi .st Qu.: 4.00 1s Median : 4.00 Me Mean : 4.42 Me Brd Qu.: 4.00 3r	engine.size in. : 61.0 st Qu.: 98.0 edian :120.0 ean :128.1 rd Qu.:146.0 ax. :326.0	fuel.system Length:193 Class :character Mode :character

Histogram of df\$horsepower



```
lm(formula = Y \sim X, data = df)
Residuals:
    Min
                   Median
              10
                                30
                                        Max
-10296.1 -2243.5 -450.1
                            1794.7 18174.9
Coefficients:
           Estimate Std. Error t value Pr(>|t|)
(Intercept) -4630.70 990.58 -4.675 5.55e-06 ***
             173.13
                          8.99
                                19.259
                                      < 2e-16 ***
X
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 4728 on 191 degrees of freedom
Multiple R-squared: 0.6601, Adjusted R-squared: 0.6583
F-statistic: 370.9 on 1 and 191 DF, p-value: < 2.2e-16
```





Quanto mais HP, mais caro é o veículo.

Em que posição a reta corta o eixo Y? R: -4630.7

Isso faz sentido? R: Não, pois a tendência dos dados é formar uma reta crescente.

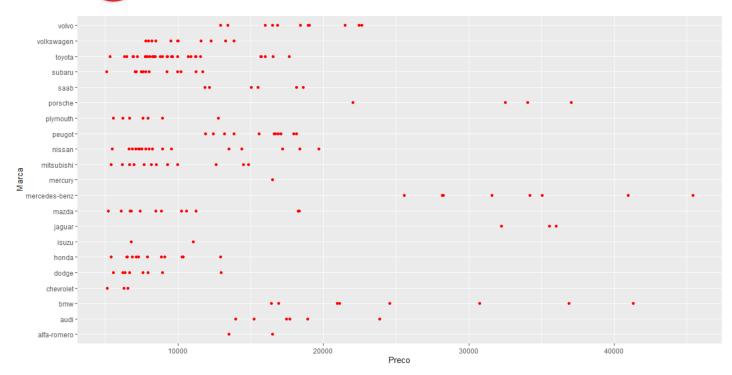
Como corrigir um modelo que apresenta este comportamento? R: Uma solução pode ser aplicar log em ambas as variáveis

```
> reg <- lm(log(Y) \sim log(X), data = df)
> summary(reg)
Call:
lm(formula = log(Y) \sim log(X), data = df)
Residuals:
     Min
                    Median
               1Q
                                 3Q
                                         Max
-0.53020 -0.18147 -0.05133 0.19204
                                     0.84852
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
            3.55712
                        0.26696
                                  13.32
                                          <2e-16 ***
(Intercept)
                        0.05814
log(X)
             1.26534
                                  21.77
                                          <2e-16 ***
               0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Signif. codes:
Residual standard error: 0.2747 on 191 degrees of freedom
                     0.7127, Adjusted R-squared:
Multiple R-squared:
F-statistic: 473.7 on 1 and 191 DF, p-value: < 2.2e-16
```

Agora temos mais simetria nos resíduos, temos um R quadrado maior, bem como o interceptador do eixo Y é um número positivo, o que condiz com dos dados, que tendem a formar uma reta crescente.

Analise: Será que apenas a potência de um carro é suficiente para termos uma boa previsão do preço deste carro?

R: Certamente não. Podemos olhar para outras variáveis como a marca e o tamanho do cilindro.



O que indica isso no seu ajuste?

R: Que para melhor explicarmos o preço dos carros, é interessante fazermos uma regressão linear multivariada e observarmos como nossa variável resposta se comporta.